

학사학위 청구논문

경계선 조건이 적대적 패치 공격 성능에 미치는 영향 분석

(Analyzing the Impact of Border Conditions on
Adversarial Patch Attack Performance)

2024년 12월 27일

숭실대학교 IT대학
전자정보공학부 IT융합전공
정 하 연

학사학위 청구논문

경계선 조건이 적대적 패치 공격 성능에 미치는 영향 분석

Analyzing the Impact of Border Conditions on
Adversarial Patch Attack Performance

지도교수 : 권 민 혜

이 논문을 학사학위 논문으로 제출함

2024년 12월 27일

송실대학교 IT대학
전자정보공학부 IT융합전공
정 하 연

정하연의 학사학위 논문을 인준함

심사위원장 김영한 (인)

심사위원 권민혜 (인)

2024년 12월 27일

송실대학교 IT대학

목 차

표 및 그림 목차	ii
국문초록	1
 I. 서론	 2
II. 배경이론	4
II-1. 적대적 패치 공격	4
II-2. 시각 작업에 대한 적대적 패치 공격	4
II-2-가. 분류	4
II-2-나. 객체 탐지	5
III. 연구 동기	6
IV. 실험	8
IV-1. 실험 설정	8
IV-1-가. 데이터셋	8
IV-1-나. 패치 생성	8
IV-1-나. 패치 크기와 비율	9
IV-2. 테두리 조건	10
IV-1-가. 보간법	10
IV-1-나. 테두리의 색상	11
IV-1-나. 테두리의 두께	12
IV-3. 평가 지표	12
V. 결과	14
V-1. 보간법의 영향	14
V-2. 패치 크기와 비율의 영향	14
V-3. 테두리 두께의 영향	16
V-3. 테두리 색상의 영향	16
VI. 결론	19
참고문헌	20
부록	24

표 및 그림 목차

표 1: 실험에서 사용된 패치의 4가지 종류	8
표 2: 테두리 색상과 두께에 따른 패치 적용 예시	12
표 3: 패치 유형과 보간법에 따른 ASR 비교	14
표 4: 다양한 패치 조건에서의 은닉 ASR	15
표 5: 다양한 패치 조건에서의 변경 ASR	17
표 6: 테두리 색상과 비율에 따른 은닉 공격 결과의 예시	18
그림 1: 입력 이미지와 첫 번째 층에서의 활성화 맵들	6
그림 2: 테두리 유무에 따른 마지막 층에서의 Grad-CAM 비교	7
그림 3: 부착 비율에 따른 생성된 INRIA_INRIA 은닉 패치의 예시	9
그림 4: 목표 클래스에 따른 생성된 변경 패치의 예시	10

경계선 조건이 적대적 패치 공격 성능에 미치는 영향 분석

전자정보공학부 IT융합전공 정 하 연
지도교수 권 민 혜

객체 탐지 모델은 적대적 패치 공격에 취약하며, 다양한 연구들이 이러한 공격을 통한 모델 예측 왜곡 방법을 탐구해 왔다. 하지만 선행 연구들은 주로 패치 내부 패턴을 최적화하는 데 초점을 맞추었고, 패치 테두리의 역할에 대해서는 거의 주목하지 않았다. 본 연구에서는 활성화 맵과 Grad-CAM을 활용하여 테두리의 존재가 CNN 기반 객체 탐지 모델의 인식 과정에 미치는 영향을 조사했으며, 테두리가 공격 성공률에 영향을 미칠 수 있음을 발견했다. 테두리 두께, 색상, 보간 방법 등 다양한 테두리 조건에서 적대적 패치의 성능을 평가하여 공격 성능에 미치는 영향을 분석했다. 또한, 패치 크기의 약 3%(4-8픽셀) 두께의 테두리가 공격 성공률을 최대 9.8%까지 향상하는 데 효과적임을 확인했다. 더불어, 회색 테두리의 사용은 거의 모든 경우에서 공격 성공률을 일관되게 향상하는 것이 관찰되었다.

I. 서 론

적대적 패치 공격(Adversarial patch attacks)은 딥러닝 모델, 특히 시각 인식 모델의 성능을 왜곡하거나 오작동을 유발하기 위해 설계된 기술이다 [1,2]. 이러한 공격은 디지털 이미지나 실체 객체에 패치를 적용하는 방식으로 이루어진다[3]. 패치는 객체를 올바르게 인식하지 못하도록 제작되며, 딥러닝 모델의 취약점을 악용하여 성공적인 공격을 달성한다[4]. 이러한 패치는 신뢰할 수 없는 결과를 초래할 수 있으며, 자율주행 차량이나 보안 시스템과 같은 중요한 응용 분야에서 상당한 위험을 초래할 수 있다. 패치는 일반적으로 다음과 같이 생성된다. 먼저 공격할 대상 객체의 이미지가 분석되어 패치가 적용될 때 모델이 오작동하도록 하는 최적의 패턴이 식별된다 [5,6]. 이 패턴은 객체가 정확하게 인식되지 않도록 픽셀 수준에서 조정된다. 다양한 환경에서의 강인성을 보장하기 위해, 패치는 밝기, 각도 및 크기와 같은 여러 요소에 대해 최적화된다[7].

그러나 이러한 패치를 이미지에 적용하는 과정은 종종 일관성이 부족하다. 예를 들어, 디지털 이미지에 패치를 적용할 때, 패치 주변에 검은색 테두리가 나타나는 경우가 있다[8,9]. 실제 환경에서는 프린트된 패치를 자를 때 깔끔하게 잘리지 않아 불규칙한 테두리가 생기거나, 손으로 패치를 잡을 공간을 확보하기 위해 의도적으로 두꺼운 테두리를 추가하기도 한다[10,11].

우리는 적대적 패치 공격에서 테두리의 존재가 CNN 기반 모델의 탐지 과정에 미치는 영향을 살펴보았다. YOLOv5 모델의 첫 번째 합성곱 층에서 추출한 활성화 맵을 분석한 결과, 패치의 테두리가 이미지 내 다른 요소들보다 더 강하게 활성화되었다. 이는 CNN의 초기 층이 주로 엣지(edge) 감지 필터로 구성되어 있기 때문으로 추정된다. 이러한 활성화는 더 깊은 층으로 전파되어 모델의 최종 결정에 상당한 영향을 미칠 수 있다. 또한, Grad-CAM 분석을 통해 테두리가 있는 패치의 경우 모델이 사람 객체보다 패치에 더 집중하는 경향이 확인되었다. 이러한 관찰을 토대로 패치 테두리가 적대적 패치 공격의 성능에 미치는 영향을 심층적으로 조사하게 되었다.

본 연구는 디지털 환경에서 패치를 배경 이미지에 적용할 때 테두리의 특성(존재 여부, 색상 유형, 두께)과 보간 방법이 ASR(Attack success rate, 공격 성공률)에 미치는 영향을 분석하고자 했다.

실험은 객체 탐지 모델이 객체를 탐지하지 못하게 하는 은닉 공격

(Hiding attack)과 하나의 객체를 다른 객체로 인식하게 만드는 변경 공격 (Altering attack)을 수행하는 패치들을 대상으로 진행했다. 실험 과정에서 패치 테두리의 두께와 색상이 공격 성능에 미치는 영향을 조사했다. 예를 들어, 테두리가 더 두꺼워지거나 특정 색상일 때 결과가 어떻게 달라지는지 분석했다. 또한, 패치 적용 시 사용할 수 있는 다양한 보간 방법을 적용하여 각 방법이 패치의 효과에 미치는 영향을 조사했다. 이러한 실험들을 통해 패치 테두리와 보간 방법이 ASR에 미치는 영향을 종합적으로 평가했다. 마지막으로, 적용 비율에 따른 변화가 결과에 미치는 영향도 함께 검토했다.

본 연구의 주요 기여점은 다음과 같다:

- 기존의 적대적 패치 연구에서 패치 테두리에 대한 고려가 부족했음을 지적하고, 테두리의 일관성 유지의 필요성을 강조한다.
- CNN 기반 객체 탐지 모델에 대한 적대적 패치 공격에서 테두리의 존재가 인식 과정에 미치는 영향을 조사했다.
- 패치 테두리의 두께, 색상, 다양한 보간 방법이 ASR에 미치는 영향을 분석하고, ASR을 향상시킬 수 있는 테두리 조건을 탐구했다.

II. 배경이론

II-1. 적대적 패치 공격

적대적 패치는 머신러닝 모델, 특히 이미지 분류기나 객체 검출기를 기만하도록 설계된 작은 이미지의 패턴이다. 이러한 패치들은 모델의 예측을 교란시키기 위해 다양한 손실 함수와 최적화 기법을 사용하여 생성된다.

패치 초기 색상은 일반적으로 무작위 노이즈나 중립적 색상(예: 회색)으로 설정된다. 패치를 갱신하고 최적화하기 위해 다양한 손실 함수들이 정의된다. 주요 손실 함수에는 목표 클래스와의 차이를 최소화하는 분류 손실, 객체 검출 모델에서 객체 검출 확률을 감소시키는 객체성 점수 손실[10], 패치의 시각적 자연스러움을 유지하는 총 변동(Total Variation, TV) 손실[19], 패치가 출력되거나 표시될 때 자연스럽게 보이도록 보장하는 비출력성 점수(Non Printable Score, NPS) 손실[18], 그리고 패치가 이미지의 덜 중요한 영역에 배치되도록 유도하는 현저성 손실[6]이 포함된다.

패치는 견고성을 향상시키기 위해 다양한 위치, 크기, 각도, 밝기 값 등의 변환을 적용하여 이미지에 부착된다. 패치가 적용된 이미지는 모델에 입력되어 예측 결과를 얻고, 정의된 손실 함수들의 값이 계산된다. 경사하강법을 사용하여 손실을 최소화하도록 패치가 갱신되며, 이 과정은 패치가 최적화될 때까지 반복된다. 최종 패치는 다양한 이미지와 시나리오에서 평가되어 목표 모델을 얼마나 효과적으로 기만하는지 검증된다. 이러한 단계들을 통해 생성된 적대적 패치는 다양한 환경에서 목표 모델을 효과적으로 기만하도록 최적화된다.

이처럼 적대적 패치 공격에 관한 연구들은 주로 패치 생성 과정에서 적용되는 손실 함수와 변환에 초점을 맞추어왔다. 그러나 본 논문에서는 패치 적용 시 발생할 수 있는 보간법과 테두리 조건의 차이에 주목한다.

II-2. 시각 작업에 대한 적대적 패치 공격

II-2-가. 분류

Brown[1]은 학습 데이터 없이도 이미지를 기만할 수 있는 적대적 패치를 제안하였다. 이 패치들은 효과적이거나 크고 눈에 띄어야 하며, 그 효과는 조건에 따라 변화한다. Karmon[20]은 주요 객체를 가리지 않으면서도 전체적인 픽셀의 2% 미만으로 높은 성공률을 달성하는 LaVAN을 제안하였으나, 이는 위치 의존성을 보인다. Liu[21]는 보다 자연스러운 적대적 패치 생성 기법을 제안하였으나, 그 성능은 맥락에 따라 변동된다. Zhou[22]은 중간층 모델 활성화를 조작하여 학습 데이터 없이도 공격을 수행하는 DiAP를 제안하였다.

II-2-나. 객체 탐지

Liu[21]가 제안한 DPatch는 객체 탐지 작업에서 테두리 상자 회귀와 객체 분류를 모두 공격할 수 있다. Lee[23]는 실제 환경의 조명과 위치 변화에 견고한 패치를 제안했으며, Madry[24]는 RGB 범위 내에서 픽셀 값을 유지함으로써 공격 효과성을 보장하였다. Song[4]은 객체 탐지를 위한 최초의 물리적 패치를 제안하여 객체를 숨기거나 거짓 탐지를 생성하는 공격을 가능케 하였다. Thys[10]는 다양한 인체 형태에 대한 효과적인 패치를 개발하였으며, Hollander[25]는 군사 자산을 은폐하기 위한 위장 패치를 제안하였다.

III. 연구 동기

패치에 관한 연구는 주로 크기를 줄이거나 눈에 띄지 않게 만드는 데 초점을 맞추어왔다. 선행 연구들이 패치의 특성을 조정하여 ASR(Attack Success Rate, 공격 성공률)을 높이려고 하였으나, 배경 이미지와 패치 사이의 픽셀 및 테두리에 대한 고려는 충분하지 않았다.

Thys[10]는 사람 감지 모델의 정확도를 크게 저하시킬 수 있는 공격을 제안하였다. 이는 다양한 인체 형태를 대상으로 하는 적대적 패치를 생성하여, 실제 환경에서 카메라로 촬영된 경우에도 효과적으로 작동함을 보였다. 그러나 디지털 및 실제 환경에서 적용된 패치들은 눈에 띄는 흰색 테두리를 가진다. Wang[11]은 고정된 디지털 패치와 달리, 물리적 환경의 패치가 회전되거나 조건이 변화해도 효과적으로 작동함을 보였다. 단, 이 연구에서 물리적 패치는 넓은 검은색 테두리를 가진 전자 디스플레이(액정 디스플레이) 화면에 표시되었다. 이와 유사하게, Tang[8]과 Sharma[9]가 수행한 적대적 패치 실험에서도 검은색 테두리의 존재가 관찰되었다.

패치 테두리가 공격에 미치는 영향을 조사하기 위해, 두 가지 관점에서 YOLOv5 모델의 테두리 포함 이미지에 대한 반응을 분석하였다. 먼저, YOLOv5의 초기 합성곱 층에서 활성화 맵을 추출한 결과(그림 1), 테두리를 가진 패치가 이미지의 다른 부분보다 현저히 강한 활성화를 보였다. 이는 CNN의 초기 층이 주로 엣지(edge) 검출 필터로 구성되어 있어 픽셀 값의 급격한 변화에 강하게 반응하기 때문이다. 초기 층에서 관찰된 강한 활성화를 고려할 때, 이러한 정보가 더 깊은 층에서 추상화되어 공격의 효과성에 상당한 영향을 미칠 수 있다는 가설을 세웠다.



그림 1: 입력 이미지와 첫 번째 층에서의 활성화 맵들

둘째로, YOLOv5의 최종 합성곱 층에 Grad-CAM을 적용한 결과(그림 2), 패치에 테두리가 있을 때 모델이 사람보다 패치에 더 주목하는 것으로 나타났다. 공격의 목적이 “숨기기”였던 만큼, 패치로의 이러한 미묘한 주의력 이동은 잠재적으로 공격 성공률을 향상시킬 수 있다. 이러한 결과들은 CNN 기반 모델에서 적대적 패치 공격의 성능이 패치 테두리의 존재에 크게 영향을 받음을 시사한다. 따라서 다양한 패치 및 테두리 조건에 대한 추가 연구가 필요하다. 더욱이 CNN 기반 모델이 연구와 실제 응용 분야에서 널리 사용되고 있는 만큼, 이러한 모델들이 공격과 방어를 위한 더욱 효과적인 방법을 개발하는 데 본 연구가 중요한 시작점이 될 것이다.



그림 2: 테두리 유무에 따른 마지막 층에서의 Grad-CAM 비교

IV. 실험

본 연구에서는 적대적 패치를 사람 객체에 적용하여 디지털 환경에서 공격을 수행할 때 테두리가 ASR(Attack success rate, 공격 성공률)에 미치는 영향을 조사한다. 이때 사람이 적대적 패치를 들고 있는 상황을 가정한다.

IV-1. 실험 설정

IV-1-가. 데이터셋

패치의 학습과 평가를 위해 Microsoft Common Objects in Context (COCO) 데이터셋[12]과 INRIA Person 데이터셋[13]을 사용하였다. COCO 데이터셋은 일상적 장면을 포함하는 80개의 객체 범주로 구성되어 있으며, 약 118,000장의 학습 이미지와 5,000장의 검증 이미지를 포함한다. 실험을 위해 COCO 검증 세트에서 “person” 클래스를 포함하는 이미지들을 선별하였다. INRIA 데이터셋은 614장의 학습 이미지와 288장의 테스트 이미지로 구성된 인체 전신 데이터를 포함한다. 이러한 데이터셋들을 활용하여 표 1과 같이 패치 학습과 공격 검증을 위한 데이터셋 조합에 따른 네 가지 유형의 적대적 패치를 생성하였다.

패치 이름	학습 데이터셋	공격 데이터셋
COCO_COCO	COCO	COCO
INRIA_COCO	COCO	INRIA
INRIA_INRIA	INRIA	INRIA
COCO_INRIA	INRIA	COCO

표 1: 실험에서 사용된 패치의 4가지 종류

또한 두 가지 You Only Look Once (YOLOv5) 모델을 사용하여 적대적 패치 공격을 평가하였다. 하나는 COCO 데이터셋으로, 다른 하나는 INRIA 데이터셋으로 학습된 모델이다.

IV-1-나. 패치 생성

은닉 공격(Hiding attack)의 목표는 YOLOv5 모델이 사람을 탐지하지 못하도록 하는 것이다. 이를 위해 COCO_COCO, INRIA_COCO, INRIA_INRIA, COCO_INRIA의 네 가지 유형의 패치를 생성하고 테스트하였다. 초기 패치

색상은 회색으로 설정하였으며, II-1 절에서 언급한 핵심성(Saliency) 손실, TV(Total Variation) 손실, NPS(Non Printable Score) 손실, 객체성(Objectness) 점수를 손실 함수로 사용하였다. 사람 클래스의 객체성 점수를 낮추기 위해 손실 가중치를 각각 1.0, 2.5, 0.1, 3.0으로 설정하였다. II-1절에서 참조한 대로 패치 변환이 적용되었다. INRIA_INRIA 은닉 패치의 생성 예시는 그림 3과 같다.





그림 3: 부착 비율에 따른 생성된 INRIA_INRIA 은닉 패치의 예시.

변경 공격은 목표 지정(Targeted)과 목표 미지정(Untargeted) 두 유형으로 분류된다. 목표 지정 공격은 모델이 특정 목표 레이블을 예측하도록 오인하는 반면, 목표 미지정 공격은 여러 가능한 레이블 중 하나를 예측하도록 한다. 본 연구에서는 테디 베어, 연, 신호등 등 다양한 클래스로 예측되는 목표 미지정 패치를 생성하였다. 손실 가중치는 핵심성 손실, TV 손실, NPS 손실, 원래 분류 점수, 목표 분류 점수에 대해 각각 0.25, 0.5, 0.1, 8.0, 6.0으로 설정하였다. 이는 사람 클래스의 분류 신뢰도를 낮추고 목표 클래스에 대한 신뢰도를 높이기 위함이다. 각 에포크에서 분류 점수가 가장 낮은 클래스를 목표 클래스로 설정하였다. 그 외 학습 조건은 숨기기 패치와 동일하게 적용하였다. 그림 4는 다양한 클래스로 예측되는 목표 미지정 변경 공격 패치의 예시를 보여준다.

IV-1-다. 패치 크기와 비율

적대적 패치를 생성할 때, 패치 크기는 픽셀 단위로 지정되어야 한다. 패치 크기가 증가함에 따라 패치 내에서 더 다양한 색상과 형태를 표현할 수 있다. 따라서 패치 생성 과정에서 설정된 초기 크기에 따라 최종 패치의 특성이 크게 달라질 수 있다. 또한, 공격자는 적용 과정에서 패치가 객체를 덮는 비율

을 결정하게 된다. 일반적으로 객체에 대한 패치의 비율이 높을수록 ASR(Attack Success Rate)이 높아진다. 이에 따라 우리는 다양한 패치 크기와 비율로 실험 환경을 구성하여 테두리 유무에 따른 각 시나리오에서 ASR의 변화를 조사한다.



(a) Kite

(b) Teddy Bear

(c) Traffic Light

그림 4: 목표 클래스에 따른 생성된 변경 패치의 예시. 왼쪽부터 오른쪽으로, 패치 크기는 각각 256×256, 128×128, 64×64 픽셀이다.

IV-2. 테두리 조건

IV-2-가. 보간법

패치를 적용할 때 고려해야 할 중요한 요소는 보간법이다. 보간법은 원본 이미지의 객체 크기에 맞추어 패치 크기를 조정하기 위해 새로운 픽셀값을 계산하여 이미지를 조정한다[14,15,16,17]. 쌍 선형(bilinear), 쌍 입방(bicubic), 최근접 이웃(nearest neighbor) 등 다양한 보간법이 개발되었으며, 각각의 방법은 서로 다른 패치 테두리 색상을 생성한다. 이는 각 방법이 패치 가장자리의 픽셀값을 서로 다르게 처리하기 때문이다.

이미지 내 객체와 적대적 패치의 정확한 정렬을 보장하기 위해 이진 마스크가 사용된다는 점에 주목해야 한다. 이 마스크는 객체 영역을 흰색 픽셀(값 1)로, 외부 영역을 검은색 픽셀(값 0)로 표시한다. 적용 과정에서 패치는 흰색 픽셀 영역에만 배치되어, 정확한 위치 지정이 가능하고 픽셀 크기나 위치의 불일치를 최소화할 수 있다.

다양한 보간법과 이를 사용한 적대적 패치 적용 시 발생하는 패치 테두리의 결과는 다음과 같다. 첫째, 쌍 선형 방법을 사용할 경우, 미지의 픽셀값은

주변 4개 픽셀의 값과 거리를 이용하여 계산된다. 적대적 패치의 이진 마스크가 패치의 외부 영역을 0으로 설정하므로, 테두리 주변에 여러 0값 픽셀이 나타나 검은색으로 보이게 된다. 둘째, 쌍 입방 방법을 사용할 경우, 새로운 픽셀값은 가까운 16개의 이웃 픽셀들의 가중 평균을 계산하여 추정되며, 더 가까운 픽셀에 더 높은 가중치가 부여된다. 쌍 선형 보간법과 유사하게, 이진 마스크의 0값 픽셀로 인해 검은색 테두리가 생성된다. 셋째, 최근접 이웃 방법을 사용할 경우, 다른 픽셀들을 고려하지 않고 가장 가까운 픽셀의 값을 직접 사용한다. 이 방법은 테두리를 가장 가까운 픽셀값으로 채우므로, 쌍 선형이나 쌍 입방 보간법에 비해 테두리가 덜 눈에 띄게 된다.

IV-2-나. 테두리의 색상


ASR에 대한 테두리 조건의 영향을 분석하기 위해 테두리 색상을 흰색, 회색, 검은색으로 다양화하였다. 표 2는 256×256 픽셀 크기의 패치에서 서로 다른 테두리 색상을 적용한 은닉 패치의 예시를 보여주며, 첫 번째, 두 번째, 세 번째 행은 각각 흰색, 회색, 검은색 테두리가 적용된 패치를 나타낸다.

IV-2-다. 테두리의 두께

테두리가 패치 자체의 시각적 인식에 과도한 영향을 미치지 않도록 하기 위해 테두리의 두께를 패치 크기의 6.25% 이하로 유지하였다. 256×256 픽셀 패치의 경우, 테두리 두께는 2(0.78%), 8(3.13%), 16(6.25%) 픽셀로 설정되었다. 128×128 픽셀 패치의 경우에는 2(1.56%), 4(3.13%), 8(6.25%) 픽셀로, 64×64 픽셀 패치의 경우에는 2(3.13%)와 4(6.25%) 픽셀로 테두리 두께가 설정되었다.

패치 적용 시 발생할 수 있는 다양한 조건들이 고려되었으며, 이에 따라 변환이 적용되었다. 가우시안 랜덤 노이즈가 추가되었고, 패치들은 다양한 각도로 회전되었으며, 객체의 서로 다른 위치에 적용되었다. 또한, 다양한 시나리오를 시뮬레이션하기 위해 대비와 밝기 값이 조정되었다.

표 2: 테두리의 색상과 두께에 따른 패치 적용 예시.

색상	두께		
	2 pixels (0.78%)	8 pixels (3.13%)	16 pixels (6.25%)
흰색			
회색			
검은색			

IV-3. 평가 지표

은닉 패치 공격은 "person"으로 레이블된 객체가 "background"로 오분류 될 때 성공적인 것으로 간주되었다. 은닉 ASR은 데이터셋 내 전체 탐지된 "person" 객체 중 "background"로 오분류된 "person" 객체의 비율이다. 은닉 ASR을 결정하기 위해 다음 수식이 사용되었다:

$$ASR_{hiding} = \frac{N_{person \rightarrow background}}{N_{person}}$$

여기서 $N_{person \rightarrow background}$ 는 "background"로 오분류된 "person" 객체의 수를 나타내며, N_{person} 은 탐지된 전체 "person" 객체의 수를 의미한다.

변경 패치 공격은 "person"으로 레이블된 객체가 목표 변경 클래스로 오분류될 때 성공적인 것으로 간주되었다. 변경 ASR은 데이터셋 내 전체 탐지된 "person" 객체 중 목표 변경 클래스로 오분류된 "person" 객체의 비율이다. 변경 ASR을 계산하기 위해 다음 수식을 사용하였다:

$$ASR_{altering} = \frac{N_{person \rightarrow target}}{N_{person}}$$

여기서 $N_{person \rightarrow target}$ 는 목표 변경 클래스로 오분류된 "person" 객체의 수를 나타내며, N_{person} 은 탐지된 전체 "person" 객체의 수를 의미한다.

V. 결과

V-1. 보간법의 영향

적대적 패치를 객체에 적용할 때, 쌍 입방 방법은 패치 주변에 검은색 테두리를 적용한 반면, 최근접 이웃 방법은 검은색 테두리 없이 패치를 적용하였다. 적대적 패치의 이진 마스크에서 패치 외부 영역이 0으로 설정되어, 테두리 주변의 여러 픽셀들이 0값을 가지게 되어 검은색 테두리가 생성되었다. 쌍 선형 보간법의 경우, 그 결과는 쌍 입방 보간법과 동일하였다. 표 3은 훈련 및 공격 데이터셋에서 서로 다른 패치에 대한 다양한 보간법의 결과를 보여준다. 여기서 사용된 패치들은 256×256 픽셀 크기였다. 우리는 앞서 언급한 4가지 유형의 은닉 패치를 사용하였으며, 객체에 적용되는 패치의 비율을 다양화하였다.

표 3: 패치 유형과 보간법에 따른 ASR 비교. 사용된 패치는 256×256 크기의 은닉 패치이다. B는 Bilinear과 Bicubic, N은 Nearest Neighbor를 의미한다.

비율	0.1		0.2		0.3		0.1-0.3	
보간법	B	N	B	N	B	N	B	N
COCO_COCO	16.8	16.8	39.7	38.2	63.9	62.9	60.4	58.8
COCO_INRIA	45.2	44.8	66.9	64.7	92.8	91.6	92.3	91.3
INRIA_COCO	7.4	7.3	32.5	31.2	72.9	71.2	55.0	54.1
INRIA_INRIA	22.1	22.1	77.7	75.3	96.2	95.8	94.7	94.2

결과는 패치 유형과 관계없이 쌍 입방 보간법을 사용할 때 ASR이 더 높다는 것을 보여준다. INRIA INRIA 패치가 0.5의 비율로 적용되었을 때 ASR이 75.3%에서 77.7%까지 차이가 나는 등, 최대 2.4%의 차이가 발생했는데, 이는 검은색 테두리가 탐지 모델에서 패치의 효과를 향상시킨다는 것을 시사한다. 이는 보간법으로 인한 픽셀값의 작은 변화도 ASR에 상당한 영향을 미칠 수 있음을 의미한다. 따라서 적대적 패치의 효과를 최대화하기 위해서는 패치 주변에 얇은 검은색 테두리를 추가하는 것이 유용할 수 있다.

V-2. 패치 크기와 비율의 영향

표 4와 표 5는 각각 다양한 테두리 조건에서의 은닉 및 변경 패치 공격의 결과를 보여준다. 우리는 테두리가 있는 경우와 없는 경우를

비교했으며, 테두리가 있는 경우에는 패치 크기와 패치 비율에 따른 차이를 조사하였다. 이 표들에서 굵은 텍스트는 테두리가 없는 조건과 비교했을 때 ASR의 최대 증가를 나타내며, 밑줄은 테두리가 없는 조건과 비교했을 때 ASR의 최소 감소 또는 유사한 경우를 나타낸다.

표 4: 다양한 패치 조건에서의 은닉 ASR(Attack Success Rate)

PATCH TYPE	PATCH SIZE	THICK-NESS	PATCH AREA RATIO								
			0.1			0.2			0.3		
			White	Gray	Black	White	Gray	Black	White	Gray	Black
INRIA-COCO	256 x 256	16	10.6	8.0	8.7	35.6	33.9	35.5	71.6	74.5	70.6
		8	10.0	7.9	8.3	35.5	34.0	<u>32.6</u>	70.8	72.8	<u>68.1</u>
		2	7.6	7.3	<u>7.0</u>	33.3	33.0	33.9	71.2	71.3	70.8
		None	7.3			31.2			71.2		
	128 x 128	8	8.5	5.0	5.9	32.1	29.4	30.3	66.9	66.4	61.6
		4	7.3	5.8	5.9	29.8	29.9	<u>28.0</u>	64.4	65.8	62.4
		2	6.9	6.9	7.3	30.2	30.5	28.7	63.9	63.7	62.1
		None	5.4			28.9			61.7		
	64 x 64	4	9.6	7.3	8.7	27.8	23.6	26.0	53.7	54.1	53.9
		2	8.3	<u>5.7</u>	6.8	24.6	<u>20.2</u>	23.3	50.0	<u>49.6</u>	51.0
		None	5.2			18.0			46.9		
INRIA-INRIA	256 x 256	16	<u>15.3</u>	21.9	18.5	<u>76.2</u>	80.2	76.8	<u>95.5</u>	96.2	96.2
		8	17.4	22.1	19.8	77.5	80.2	77.9	95.8	96.2	96.4
		2	20.0	21.5	21.7	78.9	79.2	78.1	96.2	96.2	96.4
		None	22.1			75.3			95.8		
	128 x 128	8	<u>17.2</u>	24.0	20.6	68.5	74.0	69.1	94.3	96.8	<u>94.2</u>
		4	18.9	22.5	22.3	68.7	74.3	71.5	94.9	97.0	96.0
		2	20.0	22.5	22.6	70.6	72.8	72.5	95.3	96.8	96.2
		None	21.7			71.7			96.4		
	64 x 64	4	15.3	22.1	20.6	60.0	64.2	<u>57.9</u>	<u>91.5</u>	92.8	92.1
		2	17.4	22.3	21.9	61.5	63.8	60.6	92.1	93.0	91.9
		None	22.6			63.0			91.1		

은닉 패치의 ASR 차이는 크기에 따라 큰 변동을 보이지 않았다. 우리는 "ASR 차이"를 테두리가 없는 경우와 다양한 테두리가 있는 경우들 간의 최대 차이의 절댓값으로 정의하였다. 예를 들어, 0.1의 비율로 INRIA-INRIA 패치를 적용했을 때, 256×256 픽셀 패치는 테두리가 없는 경우 22.1%의 ASR을, 16픽셀 흰색 테두리가 있는 경우 15.3%의 ASR을 보여 6.8%의 차이가 발생했다. 유사하게, 128×128 패치의 경우 테두리가 없는 경우와 8픽셀 흰색 테두리가 있는 경우 각각 21.7%와 17.2%의 ASR을 보여 4.5%의 차이가 발생했다. 64×64 패치의 경우 테두리가 없을 때 22.6%, 4픽셀 흰색 테두리가 있을 때 15.3%로 7.3%의 차이를 보였다. 또한, 0.2와 0.3 비율에서도 패치 크기에 따른 경향성이 나타나지 않아, 패치 크기가 테두리 유무에 따른 ASR 차이에 영향을 미치지 않음을 시사한다. 변경 패치의 ASR 차이 역시 패치 크기에 따라 큰 변동을 보이지 않았다.

테두리 유무에 따른 은닉 패치의 ASR 차이는 패치 적용 비율에 따라

최대 9.8%, 평균 4.5%의 차이를 보였다. ASR 차이가 대부분의 경우 양수라는 점을 고려할 때, ASR 차이의 변동은 주로 ASR 증가로 해석된다. 예를 들어, 0.1의 적용 비율을 가진 여섯 가지 패치 중 INRIA INRIA 64×64 패치가 7.3%로 최대 차이의 절댓값을 보였으며, 모든 패치의 평균값은 4.5%였다. 유사하게, 0.2의 적용 비율에서는 최대값과 평균값이 각각 9.8%와 5.1%였고, 0.3의 적용 비율에서는 7.2%와 3.4%였다. 또한, 변경 패치의 경우 패치 적용 비율에 따라 ASR이 평균 2.4% 변동을 보였다. 일반적으로 적대적 패치를 객체에 적용할 때는 객체 크기의 0.1에서 0.3 사이의 크기로 적용되는데, 이는 패치 크기가 ASR에 큰 영향을 미치지 않음을 시사한다.

V-3. 테두리 두께의 영향

ASR에 대한 테두리 두께의 영향에서 일관된 경향성은 관찰되지 않았다. 은닉 공격에서 INRIA_COCO 패치는 더 두꺼운 테두리에서 더 높은 ASR을 보인 반면, INRIA INRIA 패치는 더 두꺼운 테두리에서 더 낮은 ASR을 보였다. 변경 공격에서는 INRIA_COCO(연) 패치가 테두리 두께와 관련하여 경향성을 보이지 않은 반면, COCO_COCO(신호등) 패치는 더 두꺼운 테두리에서 더 높은 ASR을 보였다. 따라서 테두리 두께와 ASR 사이의 일관된 관계는 확인할 수 없었다.

그러나 일반적으로, 약 3% (8픽셀) 두께를 사용하는 것이 ASR을 최대 9.8% 향상시키는 것으로 나타났다. 이 특정 두께 범위는 다양한 조건에서 지속적으로 더 높은 성공률을 제공하여, ASR 개선을 위한 중요한 고려 사항이 되었다.

V-4. 테두리 색상의 영향

INRIA_COCO 은닉 패치의 경우, 테두리가 없는 상태와 비교했을 때 흰색 테두리를 사용할 때 ASR이 일반적으로 증가하여 최대 9.8% 증가와 평균 4.5% 증가를 보였다. 반대로, 검은색 테두리를 사용했을 때는 ASR이 유사하거나 감소했다. INRIA_INRIA 은닉 패치의 경우, 회색 테두리를 사용했을 때 ASR이 일반적으로 증가하여 최대 4.9% 증가와 평균 1.5%

증가를 보였다. 반면, 흰색 테두리를 사용했을 때는 ASR이 유사하거나 감소하는 경향을 보였다. 또한, 회색 선택이 데이터셋과 관계없이 일관되게 증가를 가져오는 것을 발견했다.

이러한 발견은 패치 특성이 훈련 데이터셋의 영향을 받는다는 것을 보여주며, 이는 각 패치 유형의 고유한 특성을 반영한다. INRIA_COCO 은닉 패치는 COCO 데이터셋에서 훈련된 반면, INRIA_INRIA 은닉 패치는 INRIA 데이터셋에서 훈련되었다. 각 패치가 해당 훈련 데이터셋에서 눈에 띄지 않도록 설계되었으므로, 데이터셋의 색상 특성이 테두리 색상에 따른 ASR 변화에 영향을 미친다고 추론할 수 있다. 이러한 경향은 표 5에서도 관찰될 수 있다. 모든 변경 패치는 COCO 데이터셋으로 훈련되었으며, 은닉 패치와 유사하게 흰색 테두리에서 ASR이 증가한 반면, 검은색 테두리에서는 ASR이 동일하거나 감소했다. 패치 공격의 효과를 최대화하기 위해서는 훈련 데이터셋의 특성과 일치하는 테두리 색상을 사용하는 것이 중요하다.

표 5: 다양한 패치 조건에서의 변경 ASR(Attack Success Rate)

PATCH TYPE	TARGET CLASS	PATCH SIZE	THICK-NESS	PATCH AREA RATIO					
				0.2			0.3		
				White	Gray	Black	White	Gray	Black
INRIA_COCO	Kite	512 x 512	32	4.3	4.8	<u>3.9</u>	11.5	12.2	<u>10.2</u>
			16	5.3	6.0	4.7	11.9	12.1	11.6
			8	4.3	5.7	4.4	12.2	12.1	11.8
			None	6.3			13.4		
COCO_COCO	Traffic Light	128 x 128	8	9.3	7.9	8.1	20.5	20.4	20.0
			4	8.3	7.8	7.3	21.1	20.5	20.2
			2	7.8	7.2	<u>7.2</u>	20.6	20.0	<u>19.7</u>
			None	6.8			19.4		

표 6은 테두리 색상 차이에 따른 은닉 공격 결과의 예시 이미지들을 보여준다. 이미지들은 신뢰도 순으로 정렬되어 있으며(즉, 가장 낮은 ASR에서 가장 높은 ASR 순), 여기서 사용된 패치는 INRIA_INRIA이며, ASR은 테두리가 회색일 때 가장 높고 흰색일 때 가장 낮은 경향을 보인다.

첫 번째 행은 128 × 128 크기의 패치를 0.1의 비율로 person 객체에 적용한 예시를 보여주며, 테두리 두께는 8픽셀로 0.1의 비율을 가진다. 테두리가 회색일 때만 신뢰도 점수가 0.4 이하로 떨어져 은닉 공격이 성공적으로 수행되었다. 반면, 테두리가 흰색일 때는 신뢰도 점수가 0.83으로, 실패한 공격들 중 가장 낮은 공격 성능을 보였다. 두 번째 행은 128 × 128 크기의 패치를 0.2의 비율로 person 객체에 적용한 예시를 보여주며, 테두리 두께는 8픽셀로 0.2의 비율을 가진다. 이 경우에도

테두리가 회색일 때만 은닉 공격이 성공적이었다. 마지막으로, 세 번째 행은 128×128 크기의 패치를 0.3의 비율로 person 객체에 적용한 예시를 보여주며, 테두리 두께는 2픽셀로 0.3의 비율을 가진다. 이 경우에는 흰색 테두리가 있는 패치를 제외한 모든 경우에서 공격이 성공적이었으며, 흰색 테두리의 경우에도 신뢰도 점수가 상당히 낮은 0.45를 기록했다.







White	Black	None	Gray
			
Conf Score: 0.83	Conf Score: 0.75	Conf Score: 0.48	Conf Score: Under 0.4
Fail	Fail	Fail	Success
			
Conf Score: 0.59	Conf Score: 0.52	Conf Score: 0.50	Conf Score: Under 0.4
Fail	Fail	Fail	Success
			
Conf Score: 0.45	Conf Score: Under 0.4	Conf Score: Under 0.4	Conf Score: Under 0.4
Fail	Success	Success	Success

표 6: 테두리 색상과 비율에 따른 은닉 공격 결과의 예시. 각 행에서 상단에서 하단 행으로 갈수록 0.1에서 0.3의 비율로 패치가 적용되었다. 이미지 하단에는 객체 신뢰도 점수가 나타나 있으며, 이 값이 낮을수록 ASR(Attack Success Rate)이 높다. 임계값은 0.4로 설정되었으므로, 0.4 미만의 점수는 "성공(Success)", 0.4 초과인 점수는 "실패(Failed)" 공격으로 간주된다.

VI. 결과

본 연구는 적대적 패치 연구에서 자주 간과되는 패치 테두리의 중요성을 강조하며, 일관된 테두리 조건을 유지해야 할 필요성을 강조한다. 구체적으로, 우리는 테두리가 있는 패치 이미지를 YOLOv5에 입력하고 Activation Maps와 Grad-CAM을 통해 시각적으로 분석하여, 테두리가 CNN 기반 객체 탐지 모델의 인식 과정에 상당한 영향을 미칠 수 있다는 것을 확인하였다. 또한, 우리는 어떤 패치 조건이 공격 성능에 영향을 미치는지를 구체적으로 분석하기 위한 실험을 수행하였다. 결과는 쌍 입방 보간법을 사용하면 ASR이 증가한다는 것을 보여주었다. 추가로, 패치 크기의 약 3%에 해당하는 두께의 테두리를 사용하면 ASR이 최대 약 9.8%까지 증가할 수 있으며, 회색 테두리가 평균적으로 ASR을 향상시킨다는 것을 발견했다. 이는 패치 설계 과정에서 테두리 조건을 적절히 고려하는 것이 중요하다는 것을 시사한다.

본 연구는 적대적 공격의 성공률을 향상시키는 새로운 접근 방식을 제시하며, 향후 연구는 다양한 데이터셋, 환경 조건, 그리고 더 복잡한 모델들에 걸쳐 이러한 전략들을 검증하는 것이 유익할 것이다. 궁극적으로, 이 연구는 적대적 패치 공격에 대한 더 깊은 이해를 제공하고 이에 대한 고급 방어 전략을 개발하는 데 기여할 것이다.

참고문헌

- [1] T. Brown, "Adversarial patch," *Conference on Neural Information Processing Systems*, 2017.
- [2] K. Eykholt, "Robust physical-world attacks on deep learning visual classification," *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 1625–1634, 2018.
- [3] X. Liu, "DPatch: An adversarial patch attack on object detectors," *European Conference on Computer Vision*, 2018.
- [4] D. Song, "Physical adversarial examples for object detectors," *USENIX Workshop on Offensive Technologies*, 2018.
- [5] P. Williams, "CamoPatch: An Evolutionary Strategy for Generating Camouflaged Adversarial Patches," *Advances in Neural Information Processing Systems*, vol. 36, 2024.
- [6] R. Hollander, "Adversarial patch camouflage against aerial detection," *Artificial Intelligence and Machine Learning in Defense Applications II*, p. 77–86, 2020.
- [7] J. Kim, "Camouflaged adversarial attack on object detector," *International Conference on Control, Automation and Systems*, pp. 613–617, 2021.
- [8] G. Tang, "Adversarial patch-based false positive creation attacks against aerial imagery object detectors," *Neurocomputing*, vol. 579, pp. 127431, 2024.
- [9] A. Sharma, "Adversarial patch attacks and defences in vision-based tasks: A survey," *arXiv preprint*, 2022.
- [10] S. Thys, "Fooling automated surveillance cameras: adversarial patches to attack person detection," *arXiv preprint*, 2019..

- [11] Y. Wang, "Towards a physical-world adversarial patch for blinding object detection models," *Information Sciences*, vol. 556, pp. 459–471, 2021.
- [12] T. Lin, "Microsoft coco: Common objects in context," *European Conference on Computer Vision*, pp. 740–755, 2014.
- [13] N. Dalal, "Histograms of oriented gradients for human detection," *IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, vol. 1, pp. 886–893, 2005.
- [14] A. Amanatiadis, "A survey on evaluation methods for image interpolation," *Measurement Science and Technology*, vol. 20, no. 10, pp. 104015, 2009.
- [15] D. Han, "Comparison of commonly used image interpolation methods," *Conference of Computer Science and Electronics Engineering*, pp. 1556–1559, 2013.
- [16] V. Patel, "A review on different image interpolation techniques for image enhancement," *International Journal of Emerging Technology and Advanced Engineering*, vol. 3, no. 12, pp. 129–133, 2013.
- [17] P. Parsania, "A review: Image interpolation techniques for image scaling," *International Journal of Innovative Research in Computer and Communication Engineering*, vol. 2, no. 12, pp. 7409–7414, 2014.
- [18] M. Sharif, "Accessorize to a crime: Real and stealthy attacks on state-of-the-art face recognition," *ACM SIGSAC Conference on Computer and Communications Security*, pp. 1528–1540, 2016.
- [19] A. Mahendran, "Understanding deep image representations by inverting them," *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 5188–5196, 2015.

- [20] D. Karmon, "LaVAN: Localized and visible adversarial noise," *IEEE Conference on Computer Vision and Pattern Recognition*, 2018.
- [21] R. Liu, "PS-GAN: Perceptual-Sensitive Generative Adversarial Networks," *IEEE Conference on Computer Vision and Pattern Recognition*, 2018.
- [22] X. Zhou, "DiAP: Data-independent adversarial patch," *International Conference on Learning Representations*, 2018.
- [23] J. Lee, "Real-world adversarial attacks on deep learning models for object detection," *arXiv preprint*, 2019.
- [24] A. Madry, "Towards deep learning models resistant to adversarial attacks," *arXiv preprint*, 2017.
- [25] Y. Hollander, "Camouflage adversarial patch: fooling computer vision models in the physical world," *arXiv preprint*, 2019.
- [26] J. Lu, "Patch-Noobj: Adaptive adversarial patch for evading object detection models," *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2020.
- [27] Q. Wang, "Invisibility cloak: Fooling the computer vision models," *arXiv preprint*, 2020.
- [28] Y. Hu, "Naturalistic physical adversarial patch for object detectors," *IEEE/CVF International Conference on Computer Vision*, pp. 7848–7857, 2021.
- [29] K. Xu, "Adversarial t-shirt! evading person detectors in a physical world," *European Conference on Computer Vision*, pp. 665–681, 2020.
- [30] Y. Zhao, "Seeing isn't believing: Towards more robust adversarial attack against real world object detectors," *ACM SIGSAC Conference on Computer and Communications Security*, pp. 1989–2004, 2019.

- [31] G. Jocher, "YOLOv5 by Ultralytics," May 2020.
- [32] N. Carlini, "Towards evaluating the robustness of neural networks," / *EEE Symposium on Security and Privacy*, pp. 39-57, 2017.
- [33] S. Chen, "Shapeshifter: Robust physical adversarial attack on faster r-cnn object detector," *European Conference on Machine Learning and Knowledge Discovery in Databases*, pp. 52-68, 2019.

부 록

1. 활성화 맵	25
2. Grad-CAM	26

부록 1. 활성화 맵

그림 1은 원본 이미지와 테두리가 있는 경우와 없는 경우의 서로 다른 크기로 적용된 적대적 패치가 있는 이미지들을 보여준다.

그림 2와 3은 YOLOv5의 첫 번째 합성곱 계층에서 추출된 활성화 맵을 보여준다. 테두리가 있는 패치에서 활성화가 더욱 두드러진다. 이는 초기 계층이 주로 픽셀 값의 급격한 변화에 강하게 반응하는 에지 검출 필터로 구성되어 있기 때문이다.

주목할 만한 관찰은 패치의 부착 비율과 관계없이 패치 테두리가 일관되게 활성화된다는 점이다. 그림 2의 0.2 크기 패치와 그림 3의 0.3 크기 패치를 비교해 보면, 패치 크기의 차이에도 불구하고 테두리를 따라 활성화 강도가 유사함을 알 수 있다. 이는 패치 크기와 관계없이 테두리의 존재 자체가 활성화에 중요한 요인임을 시사한다.

초기 계층의 이러한 강한 활성화는 더 깊은 계층으로 전파되어 공격의 효과성에 상당한 영향을 미칠 수 있다. 특히, 패치 크기와 관계없이 일관된 테두리 활성화는 다양한 크기의 패치를 사용하는 공격이 패치 테두리의 영향을 받을 수 있음을 시사한다. 이는 테두리 디자인이 적대적 패치 공격의 효과성에 중요한 요인이 될 수 있음을 의미한다.





그림 1: 원본 이미지: (a) 패치가 없는 경우, (b) 0.2 크기 패치, 테두리 없음, (c) 0.3 크기 패치, 경계선 없음.




(a) 테두리가 없는 경우



(b) 테두리가 있는 경우

그림 2: 0.2 크기 패치에 대한 YOLOv5의 첫 번째 합성곱 계층의 활성화 맵



(a) 경계선이 없는 경우



(b) 경계선이 있는 경우

그림 3: 0.3 크기 패치에 대한 YOLOv5의 첫 번째 합성곱 계층의 활성화 맵

부록 2. Grad-CAM

그림 4와 5는 YOLOv5의 탐지 모듈의 최종 합성곱 계층에서 얻은 Grad-CAM 결과를 보여준다. 이러한 결과는 경계로 둘러싸인 적대적 패치에 모델이 더 집중적으로 주목함을 명확히 보여준다. 이러한 증가된 주목도는 사람 객체를 숨기려는 패치의 의도된 목적에 대한 더 높은 성공률을 의미한다. 주목할 만한 점은 경계의 색상(검정 vs. 흰색)이 이러한 행동에 미치는 영향이 미미했다는 것이다; 두 경계 유형 모두 패치에 대한 모델의 주의를 상당히 증가시켰다. 이러한 발견은 색상과 관계없이 경계의 존재 자체가 모델의 행동에 상당한 영향을 미친다는 것을 시사한다. 이는 적대적 공격의 맥락에서 다양한 경계 특성(두께, 패턴 등)이 모델 성능에 어떻게 영향을 미치는지에 대한 추가 연구의 필요성을 강조한다.

요약하면, 이러한 결과들은 CNN 기반 모델에 대한 적대적 패치 공격의 성능이 패치 경계의 존재에 의해 상당한 영향을 받는다는 것을 시사한다. CNN 기반 모델이 연구와 실제 응용 분야에서 계속해서 널리 사용되고 있다는 점을 고려할 때, 이 연구는 이러한 모델들을 공격하고 방어하는 효과적인 방법을 개발하는 데 매우 중요하다.



(a) 경계선 없음

(b) 검은색 경계선 있음

그림 4: YOLOv5의 탐지 모듈의 최종 합성곱 계층에서의 Grad-CAM 시각화



(a) 경계선 없음

(b) 흰색 경계선 있음

그림 5: YOLOv5의 탐지 모듈의 최종 합성곱 계층에서의 Grad-CAM 시각화