

Phonetic-Aware Encoder Tuning: Boosting Robustness against L2 Pronunciation Variations via CTC Supervision

Project Update 2

2026.03.26

Hayeon Jeong


1. Problem Statement

“Automatic Speech Recognition (ASR)”


한국인들만 알아볼 수 있게 작성하겠습니다. 역에선 30초도 안 걸릴 만큼 가깝지만 숙소가 많이 낙후되어 있고, 엘베 없고, 4층이라 집 많으면 고생합니다. 바퀴벌레 나왔고 화장실 많이 낡았습니다. 절대 **여기**로 오지 마세요.

한국인들만 알아볼 수 있게 작성하겠습니다. 역에선 30초 **또한** 걸릴 만큼 가깝지만 숙소가 많이 낙후되어 **입구에 배 없고** 4층이라 집 많으면 고생합니다. **밖에** 벌레 나왔고 화장실 많이 낡았습니다. 절대 **여기**로 오지 마세요.

**Result of Whisper by OpenAI*




3. Background and Related Works






한국인들만 알아볼 수 있게 작성하겠습니다. 역에선 30초 **또한** 걸릴 만큼 가깝지만 속소가 많이 낙후되어 **입구에 배 얹고** 4층이라 집 많으면 고생합니다. **밖**에 벌레 나왔고 화장실 많이 낡았습니다. 절대 **역기**로 오지 마세요.

-> Timeline



H1: Layers

- 레이어별 mean CER 차이가 작다 (X)
- late-layer에서 instability가 커진다 (O)




H3: Articulatory Feature

- Articulatory(조음(調音)) Feature

phoneme	place	manner	laryngeal
ㄱ	bilabial	stop	lax
ㅋ	bilabial	stop	tense
ㆁ	bilabial	stop	aspirated
ㄷ	bilabial	nasal	voiced
ㄷ	alveolar	stop	lax
ㄸ	alveolar	stop	tense
ㄹ	alveolar	stop	aspirated
ㄴ	alveolar	nasal	voiced
ㄷ	alveolar	fricative	lax
ㄷ	alveolar	fricative	tense
ㅈ	alveolar	affricate	lax
ㅊ	alveolar	affricate	tense
ㅊ	alveolar	affricate	aspirated
ㄷ	alveolar	liquid	voiced
ㄱ	velar	stop	lax
ㄱ	velar	stop	tense
ㅋ	velar	stop	aspirated
ㅇ	glottal	nasal	voiced
ㅎ	glottal	fricative	aspirated

vowel	height	backness	rounding
ㅣ	high	front	unrounded
ㅏ	mid	front	unrounded
ㅓ	low-mid	front	unrounded
ㅕ	low	front-central	unrounded
ㅡ	high	central	unrounded
ㅗ	mid	back-central	unrounded
ㅜ	mid	back	rounded
ㅝ	high	back	rounded



H3: Articulatory Feature

Research Hypothesis 3

“Articulatory Feature에 따른
N개의 Head를 훈련하면 성능이 향상될 것
이다.”

(또한, confusion matrix에 기반한 분석이 더 정교해
지고,
그 분석 결과를 국소적 추가 개선에 활용할 수 있을

ㅍ → ㅍ

place: bilabial (correct)

manner: stop (correct)

laryngeal: aspirated → tense (error)

ㄱ → ㄱ

place: velar (correct)

manner: stop (correct)

laryngeal: lax → tense (error)

ㅏ → ㅏ

height: mid → mid (correct)

backness: central → back (error)

rounding: unrounded → rounded (error)




EXAMPLE ANALYSIS

- JP 화자는 laryngeal contrast를 많이 틀린다
- CN 화자는 rounding/backness vowel feature에서 오류가 많다
- VN 화자는 coda nasal place에서 오류가 많다

symbol error 분석 □ phonological (음운론적인) feature error 분석





H3: Articulatory Feature





- L_{ART}
 - $L_{place}^{CTC} = CTC(P_{place}, g_{place}(y))$
 - $L_{manner}^{CTC} = CTC(P_{manner}, g_{manner}(y))$
 - $L_{laryngeal}^{CTC} = CTC(P_{laryngeal}, g_{laryngeal}(y))$
 - $L_{height}^{CTC} = CTC(P_{height}, g_{height}(y))$
 - $L_{backness}^{CTC} = CTC(P_{backness}, g_{backness}(y))$
 - $L_{rounding}^{CTC} = CTC(P_{rounding}, g_{rounding}(y))$
- L_{ASR}

H3: Articulatory Feature


- On Training...



Results



Confusion Matrix



- NG->N
- eo->o, o->eo
- u->eu
- CH->J, J->CH
- G->K
- P->PP

place (조음 위치)

backness (전후설성) / 일부 height (모음 높이)

backness (전후설성) / 일부 height (모음 높이)

laryngeal (후두 특성 / 발성 유형)

backness (전후설성) / 일부 height (모음 높이)

laryngeal (후두 특성 / 발성 유형)

- rounding (원순성)

All 6 heads needed?

- No auxiliary
 - Single phoneme CTC
 - H3 full (6 heads)
 - H3 - place
 - H3 - manner
 - H3 - laryngeal
 - H3 - height
 - H3 - backness
 - H3 - rounding
- **Feature Error Rate**
 - 정답 place sequence: [velar, coronal, velar]
 - 예측 place sequence: [velar, coronal, glottal]

Appendix

H3: Articulatory Feature


- 기존 H1/H2는 모두 "phoneme-level auxiliary CTC"를 전제로 한다.
- 하지만 learner speech 오류는 phoneme symbol 자체보다 더 낮은 수준의 articulatory contrast에서 반복되는 경우가 많다.
- 예를 들면:
 - 일본어 화자는 laryngeal contrast에서 흔들릴 수 있다.
 - 베트남어 화자는 종성 nasal의 place에서 흔들릴 수 있다.
 - 중국어 화자는 모음 backness/rounding에서 흔들릴 수 있다.
- 따라서 H3의 직관은 다음과 같다.
 - phoneme symbol 하나를 한 번에 맞추라고 하기보다
 - encoder가 그 음소를 구성하는 articulatory dimension들을 따로 보게 만들면
 - learner speech variation을 더 잘 일반화할 수 있다.

Hypothesis

- Encoder의 Middle Layer만 사용하거나, 모두 사용하되 Middle Layer에 가중치를 더 준다면 성능이 향상될 것이다.
 - Baseline A:** encoder-only LoRA
 - Baseline B:** encoder-only LoRA + **final-layer phonetic CTC (현재 방식)**
 - Proposed C:** encoder-only LoRA + **single intermediate-layer phonetic CTC**
 - Proposed D:** encoder-only LoRA + **multi-layer phonetic CTC (예: mid + final)**
- Regularization이나 Smoothing과 같은 완화 기법을 적용하면 보다 안정적인 정렬을 형성하고 L2 발음 변이에 대한 강건성을 개선할 수 있다.
 - Alignment Sharpness 정량화 (New Evaluation Metrics)
 - Entropy Regularization
- Articulatory Feature에 따른 N개의 Head를 훈련하면 성능이 향상될 것이다.


phoneme	place	manner	laryngeal
ㅏ	labial	stop	fax
ㅑ	labial	stop	tense
ㅓ	labial	stop	aspirated
ㅗ	labial	nasal	voiced
ㅛ	alveolar	stop	fax
ㅜ	alveolar	stop	tense
ㅠ	alveolar	stop	aspirated
ㅡ	alveolar	nasal	voiced
ㅗ	alveolar	fricative	fax
ㅛ	alveolar	fricative	tense
ㅜ	alveolar	affricate	fax
ㅠ	alveolar	affricate	tense
ㅗ	alveolar	affricate	aspirated
ㅛ	alveolar	liquid	voiced
ㅜ	velar	stop	fax
ㅠ	velar	stop	tense
ㅑ	velar	stop	aspirated
ㅓ	glottal	nasal	voiced
ㅕ	glottal	fricative	aspirated

vowel	height	backness	rounding
ㅏ	high	front	unrounded
ㅑ	mid	front	unrounded
ㅓ	low-mid	front	unrounded
ㅗ	low	front-central	unrounded
ㅛ	high	central	unrounded
ㅜ	mid	back-central	unrounded
ㅠ	mid	back	rounded
ㅡ	high	back	rounded



X
81
0

Results



- 초/중반 레이어들에서의 Jamo-CER 개선이 뒤쪽보다 낮다?

* Additional Evaluation Methods

- 어려운 샘플을 고쳤는가
- 원래 맞던 샘플까지 괜히 건드렸는가