

Phonetic-Aware Encoder Tuning: Boosting Robustness against L2 Pronunciation Variations via CTC Supervision

Project Update 4

2026.05.21

Hayeon Jeong


Recap

“Automatic Speech Recognition (ASR)”

한국인들만 알아볼 수 있게 작성하겠습니다.
역에선 30초 **도 안** 걸릴 만큼 가깝지만 숙소가
많이 낙후되어 **있고, 열배 없고**, 4층이라 집 많
으면 고생합니다. **바퀴** 벌레 나왔고 화장실 많
이 낡았습니다. 절대 **여기**로 오지 마세요.

한국인들만 알아볼 수 있게 작성하겠습니다.
역에선 30초 **또한** 걸릴 만큼 가깝지만 숙소가
많이 낙후되어 **입구에 배 없고** 4층이라 집 많
으면 고생합니다. **밖에** 벌레 나왔고 화장실 많
이 낡았습니다. 절대 **여기**로 오지 마세요.

**Result of Whisper by OpenAI*



한국어 조음 위치

phoneme	Place (조음 위치)	Manner (조음 방법)	Laryngeal (후두 특성)
ㅂ	bilabial	stop	lenis
ㅃ	bilabial	stop	tense
ㅍ	bilabial	stop	aspirated
ㄷ	alveolar	stop	lenis
ㄸ	alveolar	stop	tense
ㅌ	alveolar	stop	aspirated
ㄱ	velar	stop	lenis
ㄲ	velar	stop	tense
ㅋ	velar	stop	aspirated
ㅈ	alveolo-palatal	affricate	lenis
ㅉ	alveolo-palatal	affricate	tense
ㅊ	alveolo-palatal	affricate	aspirated
ㅅ	alveolar	fricative	lenis
ㅆ	alveolar	fricative	tense
ㅎ	glottal	fricative	None
ㅁ	bilabial	nasal	None
ㄴ	alveolar	nasal	None
ㅇ	velar	nasal	None
ㄹ	alveolar	liquid	None



조음 방법		입술 소리	혀끝 소리	센입천장 소리	여린입천장소리	목청 소리
조음 위치						
구개음	파열음	예사소리	ㅂ	ㄷ		ㄱ
		된소리	ㅃ	ㄸ		ㄲ
		거센소리	ㅍ	ㅌ		ㅋ
	파찰음	예사소리			ㅈ	
		된소리			ㅉ	
		거센소리			ㅊ	
	마찰음	예사소리		ㅅ		ㅎ
		된소리		ㅆ		
울림소리	비음	ㅁ	ㄴ		ㅇ	
	유음		ㄹ			

vowel	Height (모음 높이)	Backness (전후설성)	Rounding (원순성)
ㅣ	high	front	unrounded
ㅐ	mid	front	unrounded
ㅙ	low-mid	front	unrounded
ㅏ	low	front-central	unrounded
ㅡ	high	central	unrounded
ㅗ	mid	back-central	unrounded
ㅜ	high	back	rounded
ㅝ	mid	back	rounded

단모음 체계표				
혀의 앞뒤 혀의 높이	전설모음		후설모음	
	평순	원순	평순	원순
고모음	ㅣ	ㅑ	ㅡ	ㅜ
중모음	ㅐ	ㅖ	ㅔ	ㅟ
저모음	ㅙ		ㅓ	

Hypothesis

- 이번 실험에서 제외한 레이어
 - 0-2: raw acoustic 비중이 너무 크고 class 분리가 불안정할 수 있음
 - 11-12: late/final CTC가 언어에 따라 불안정했었음 + text alignment bias가 클 수 있음



1. Laryngeal (후두 특성): early

- 예사소리/된소리/거친소리: ㄱ/ㄲ/ㅋ, ㄷ/ㄸ/ㅌ처럼 평음/경음/격음을 가르는 정보
- 이러한 차이는 자음이 터지는 순간과 그 직후의 아주 짧은 구간에 많이 들어 있음
 - 언제 성대 진동이 시작되는지 (VOT)
 - 숨이 얼마나 세게 빠지는지 (aspiration)
 - 바로 뒤 모음이 어떤 pitch로 시작하는지 (onset F0)
- 이런 신호는 소리 초반의 짧은 구간에 몰려 있기 때문에, 모델 안에서도 입력 음향에 더 가까운 이른 레이어가 이 정보를 더 직접적으로 갖고 있을 가능성이 크다.
- Aspiration (거센소리) 관련 논문으로부터 얻을 수 있는 보조 근거*
 - HuBERT의 초반 레이어에서 Aspiration 구분이 이미 끝난다.




Figure 2: Layer-wise performance of HuBERT models on phonetic and phonemic classifiers; log-mel classifier baselines in red.

조음 방법		입술 소리	혀끝 소리	센입천장 소리	여관입천장 소리	목청 소리
아래쪽 소리	파열음	예사소리 ㄱ	ㄷ		ㄱ	
		된소리 ㄲ	ㄸ		ㄴ	
		거센소리 ㅋ	ㅌ		ㅋ	
	파찰음	예사소리 ㅈ		ㅈ		
		된소리 ㅉ		ㅉ		
		거센소리 ㅊ		ㅊ		
울림 소리	마찰음	예사소리 ㅅ	ㅅ			ㅎ
		된소리 ㅆ	ㅆ			
울림 소리	비음	ㅁ	ㄴ		ㅇ	
	유음		ㄹ			

단모음 체계표					
혀의 앞뒤		전설모음		후설모음	
혀의 높이	입술 모양	평순	원순	평순	원순
	고모음	ㅣ	ㅜ	ㅡ	ㅗ
	중모음	ㅐ	ㅓ	ㅔ	ㅖ
	저모음	ㅐ		ㅓ	

2. place(조음 위치): early-mid

- 어디에서 막고 터뜨렸는가를 구분하는 정보
 - 입술 소리 (bilabial)
 - 혀끝 소리 (alveolar)
 - 센입천장 소리 (alveolo-palatal)
 - 여린입천장 소리 (velar)
 - 목청 소리 (glottal)
- place는 laryngeal처럼 아주 순간적인 정보만 보는 것도 아니고, 반대로 모음처럼 긴 안정 구간을 보는 것도 아님*
 - Burst: 자음이 터질 때 나는 아주 짧은 소리
 - release noise: 터진 직후 잠깐 나는 잡음
 - spectral shape: 그 짧은 소리의 주파수 모양
 - formant transition(following-vowel): 자음 다음 모음으로 넘어갈 때 소리 모양이 어떻게 변하는지
- 예시:
 - ㄱ 같은 연구개음은 뒤쪽에서 만들어져서 → 뒤따르는 모음으로 넘어갈 때 transition 패턴이 다르고
 - ㄷ 같은 치조음은 앞쪽에서 만들어져서 → 또 다른 transition 패턴이 나옴
- “자음 터지는 순간 + 그 다음 모음으로 넘어가는 짧은 변화” 까지 같이 봐야 잘 구분되는 경우가 많음

조음 방법		입술 소리	혀끝 소리	센입천장 소리	여린입천장 소리	목청 소리
조음 위치						
아음성 소리	파열음	예사소리 ㅍ	ㄲ		ㅋ	
		된소리 ㅂ	ㅃ		ㅅ	
		거센소리 ㅍ	ㅆ		ㅈ	
	파찰음	예사소리		ㅈ		
		된소리		ㅉ		
		거센소리		ㅊ		
	마찰음	예사소리	ㅅ			ㅎ
		된소리	ㅆ			
	울림소리	비음 ㅁ	ㄴ		ㅇ	
		유음	ㄹ			
단모음 체계표						
혀의 앞뒤		전설모음		후설모음		
혀의 높이	입술 모양	평순	원순	평순	원순	
	고모음	ㅣ	ㅜ	ㅡ	ㅗ	
	중모음	ㅐ	ㅓ	ㅔ	ㅖ	
	저모음	ㅐ		ㅑ		

3. manner(조음 방법): mid

- Manner: 어떻게 냈는가를 보는 정보
 - stop(파열음): 막았다가 터뜨림
 - fricative(마찰음): 좁은 틈으로 계속 마찰냄
 - affricate(파찰음): 터뜨린 뒤 바로 마찰이 이어짐
 - nasal(비음): 코로 울림
 - liquid(유음): ㄹ 같은 흐르는 패턴
- 소리가 짧게라도 어떻게 흘렀는지를 조금 봐야함
- 예시
 - ㅈ은 막았다가 + 마찰
 - ㅅ은 처음부터 마찰

조음 방법		입술 소리	혀끝 소리	센입천장 소리	여린입천장소리	목청 소리
안아음소리	파열음	예사소리 ㄱ	ㄴ	ㄷ	ㄹ	
	파열음	된소리 ㄲ	ㄴ	ㄸ	ㄹ	
	파열음	거센소리 ㅋ	ㄴ	ㅌ	ㄹ	
	파찰음	예사소리 ㅈ		ㅊ		
	파찰음	된소리 ㅊ		ㅈ		
	파찰음	거센소리 ㅉ		ㅊ		
	마찰음	예사소리 ㅅ	ㅅ			ㅎ
	마찰음	된소리 ㅆ	ㅆ			
	울림소리	비음 ㅇ	ㅁ	ㄴ	ㅇ	
	유음		ㄹ			
단모음 체계표						
혀의 앞뒤		전설모음		후설모음		
혀의 높이	입술 모양	평순	원순	평순	원순	
고모음		ㅣ	ㅍ	ㅡ	ㅓ	
중모음		ㅐ	ㅕ	ㅖ	ㅗ	
저모음		ㅐ		ㅓ		

4. height(모음 높이), backness(전후설성), rounding(원순성) : mid-late

- 모음이 어느 정도 펼쳐져서 안정적으로 들리는 구간을 봐야 함
- 구분
 - height(높이)
 - 입을 얼마나 벌렸는지
 - 비교적 먼저 잡힐 수 있음
 - backness(전후설성)
 - 혀가 앞/뒤 어디 있는지
 - 화자 차이, 앞뒤 자음 영향 때문에 더 헛갈릴 수 있음
 - rounding(원순성)
 - 입술을 둥글게 했는지
 - backness랑 같이 움직이는 경우가 많아서 더 뒤에 뒤도 됨

조음 방법		입술 소리	혀끝 소리	센입천장 소리	여린입천장 소리	목청 소리
안정된 소리	파열음	예사소리	ㅂ	ㅍ		ㅍ
		된소리	ㅃ	ㅑ		ㅑ
		거센소리	ㅍ	ㅑ		ㅑ
	파찰음	예사소리		ㅈ		
		된소리		ㅉ		
		거센소리		ㅊ		
	마찰음	예사소리		ㅅ		ㅎ
		된소리		ㅆ		
	울림소리	비음	ㅁ	ㄴ	ㅇ	
		유음		ㄹ		

단모음 체계표					
혀의 앞뒤		전설모음		후설모음	
입술 모양		평순		원순	
혀의 높이	고모음	ㅣ	ㅓ	ㅡ	ㅗ
	중모음	ㅕ	ㅛ	ㅜ	ㅟ
	저모음	ㅖ		ㅝ	

*Additional Metrics

- **CCR: Contrast Confusion Rate**

- head h , 정답 label a , 오답 label b 에 대해
- $CCR_h(a \rightarrow b) = \frac{\text{count}(gt=a, pred=b)}{\text{count}(gt=a)}$
- 정답이 a 일 때, 모델이 b 로 헛갈리는 비율
- 예시:
 - place에서 alveolar $\rightarrow$ alveolo-palatal
 - laryngeal에서 lenis $\rightarrow$ aspirated

- **ΔCCR : Contrast Confusion Change**

- $\Delta CCR_h(a \rightarrow b) = CCR_{system}(a \rightarrow b) - CCR_{baseline}(a \rightarrow b)$
- 해석:
 - 음수: 좋아짐
 - 양수: 나빠짐

- **Recovery**

- baseline은 틀렸는데 system은 맞춘 개수
- 예시:
 - GT = alveolar
 - Baseline = alveolo-palatal
 - System = alveolar

- **Regression**

- baseline은 맞았는데 system이 틀린 개수
- 예시:
 - GT = alveolar
 - Baseline = alveolar
 - System = alveolo-palatal

- **Net Recovery Rate**


- $NRR_h(a \rightarrow b) = \frac{(Recovery - Regression)}{\text{count}(gt=a)}$
- 해석:
 - 양수: 개선
 - 음수: 악화

* Baseline

• 모델의 종류

- tiny: 39M
- base: 74M
- small: 244M
- medium: 769M
- large: 1.55B
- large-v2: 1.55B
- large-v3: 1.55B
- large-v3-turbo: 809M


Whisper scale on low-proficiency learner speech



• 데이터 종류


- Low
- Low-Mid
- Low-Mid-High

SentenceSpeechLV Distribution by L1 Background
(131 Korean WAV Dataset - Training Split)




Experiment Results


laryngeal=4
laryngeal=3, place=5, manner=6, height=8, backness=9, rounding=10
laryngeal=2



$$\Delta CCR_h(a \rightarrow b) = CCR_{system}(a \rightarrow b) - CCR_{baseline}(a \rightarrow b)$$




$$NRR_h(a \rightarrow b) = \frac{(Recovery - Regression)}{count(gt = a)}$$




Experiment Results


laryngeal=3, place=6, place=5, manner=6, height=8, backness=9, rounding=10
place=4



$$\Delta CCR_h(a \rightarrow b) = CCR_{system}(a \rightarrow b) - CCR_{baseline}(a \rightarrow b)$$




$$NRR_h(a \rightarrow b) = \frac{(Recovery - Regression)}{count(gt = a)}$$




Experiment Results

laryngeal=3, place=5, manner=7, height=8, backness=9, rounding=10
manner=6, manner=5


Manner layer sweep: official evaluation



$$\Delta CCR_h(a \rightarrow b) = CCR_{system}(a \rightarrow b) - CCR_{baseline}(a \rightarrow b)$$




$$NRR_h(a \rightarrow b) = \frac{(Recovery - Regression)}{count(gt = a)}$$




Experiment Results

laryngeal=3, place=5, manner=6, height=9, backness=9, rounding=10
height=8
height=7


Height layer sweep: official evaluation



$$\Delta CCR_h(a \rightarrow b) = CCR_{system}(a \rightarrow b) - CCR_{baseline}(a \rightarrow b)$$




$$NRR_h(a \rightarrow b) = \frac{(Recovery - Regression)}{count(gt = a)}$$




Experiment Results


laryngeal=3, place=5, manner=6, height=8, backness=9, rounding=10
backness=10
backness=8



$$\Delta CCR_h(a \rightarrow b) = CCR_{system}(a \rightarrow b) - CCR_{baseline}(a \rightarrow b)$$




$$NRR_h(a \rightarrow b) = \frac{(Recovery - Regression)}{count(gt = a)}$$




Experiment Results


laryngeal=3, place=5, manner=6, height=8, backness=9, rounding=10
rounding=11
rounding=9



$$\Delta CCR_h(a \rightarrow b) = CCR_{system}(a \rightarrow b) - CCR_{baseline}(a \rightarrow b)$$



$$NRR_h(a \rightarrow b) = \frac{(Recovery - Regression)}{count(gt = a)}$$



Next Plan

- 특성 별 극단적인 변화에 따른 성능 변화
- Limitation of Grid Search...
- A better way to analyze the results

* Feedback

- Framing: 표준 화자 기준 ASR가 과하게 의존하는 cue를 줄이고, 학습자 발화에 남아 있는 다른 cue도 쓰게 만들어야.
- Ground Truth 음성을 제작해서, 내부 representation의 진행 방향?을 비교해보기
 - 내가 제안한 방법으로 하면 개선이 되는지? GT와 비슷하게 가는지?